

Deep Learning Using MNIST and CIFAR10

Neemias Bucéli
Gabriel Nunes

neemiasbsilva@gmail.com
<https://cPPP.ufms.br>

Universidade Federal de Mato Grosso do Sul – Campus de Ponta Porã
Inteligência Artificial

22 de Novembro de 2018

Sumário

Introdução

MNIST and CIFAR10

Classificadores e Métricas

Otimização

Redes Neurais Artificiais

Resultados e Conclusão

Referência Bibliográfica

Sumário

Introdução

MNIST and CIFAR10

Classificadores e Métricas

Otimização

Redes Neurais Artificiais

Resultados e Conclusão

Referência Bibliográfica

Introdução

- A importância da base de dados **MNIST** (*Modified National Institute of Standards and Technology database*) [NIST, 2018].
- Será apresentada técnicas para prever os dígitos da base **MNIST**;
- Em linhas gerais apresentaremos a base de dados CIFAR10;
- A abordagem utilizada será aprendizado *supervisionado* utilizando *classificação*;
- Será mostrado, também, dois modelos de classificadores: *k-nearest neighbor* e *classifier linear*;
- Arquiteturas das redes neurais;
- Redes Neurais Profundas;

Sumário

Introdução

MNIST and CIFAR10

Classificadores e Métricas

Otimização

Redes Neurais Artificiais

Resultados e Conclusão

Referência Bibliográfica

MNIST

- O *MNIST* é uma base de dados, de dígitos manuscritos, que é subdividido em conjunto de 60,000 amostras para treinamento e 10,000 amostras que podem ser usadas para se fazer testes de eficiência e técnicas de classificação de dígitos manuscrito [David C. S. Vieira et al., 2012].
- É importante salientar que a base de dados é uma amostra do **HFCD** (Handprinted Forms and Characters Database) [Patrick et. al, 1995].

MNIST

- O conjunto de exemplos são caracteres escaneados em forma de imagens;
- As imagens resultantes contêm uma variação em níveis de cinza e todas são normalizadas em uma dimensão de 28x28.




Figure: Conjunto de imagens da base MNIST.[Available]

CIFAR10

- CIFAR10 é uma base de dados muito popular para a abordagem de classificação;
- A base de dados consiste em 60,000 imagens de 32 pixels tanto de largura como de altura;
- Estas 60,000 imagens são particionada, geralmente em, 50,000 imagens para o conjunto de treinamento e 10,000 para o conjunto de teste.
- Este conjunto de dados possui 10 classes: *avião, automóvel, pássaro, gato, veado, sapo, cavalo, barco e caminhão*.

CIFAR10

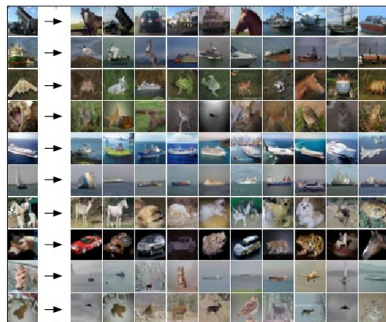
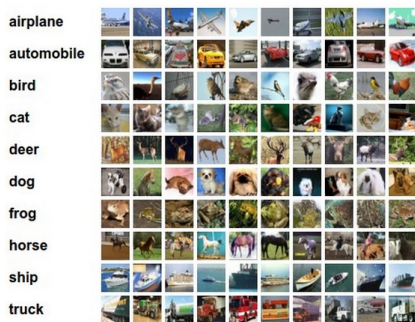


Figure: Amostra do conjunto de dados CIFAR10 [CIFAR10, 2017]

Sumário

Introdução

MNIST and CIFAR10

Classificadores e Métricas

Otimização

Redes Neurais Artificiais

Resultados e Conclusão

Referência Bibliográfica

K - Nearest Neighbors

- Não é muito utilizado em *Redes Neurais* utilizando imagens, pois existem classificadores mais eficientes;
- Mas é fácil de ter uma ideia sobre a abordagem de classificação de uma imagem.
- O objetivo deste classificador é utilizar a distância de seus vizinhos para determinar qual grupo se encontra.

$$L1 : d_1(l_1, l_2) = \sum_p^N |l_1^p - l_2^p|. \quad (1)$$

Classificador Linear

- Objetivo deste classificador é dar um **score** para que o dado seja classificado;
- Através deste classificador que podemos ter uma ideia do que seja uma rede neural;

$$f(x_i, W, b) = Wx_i + b \quad (2)$$

- Objetivo do classificador é determinar (ou prever) a classe do conjunto de teste.

Métricas

Métricas		
Métricas	Fórmula	Descrição
Acurácia	$\frac{TN+TP}{TN+TP+FP+FN}$	Calcula toda a performance do modelo
Erro	$\frac{FP+FN}{TN+TP+FP+FN}$	Calcula a taxa de erro do modelo
Precisão	$\frac{TP}{TP+FP}$	Acurácia apenas para os valores positivos
....

Table: Algumas métricas para calcular os classificadores - Neemias Bucéli

Sumário

Introdução

MNIST and CIFAR10

Classificadores e Métricas

Otimização

Redes Neurais Artificiais

Resultados e Conclusão

Referência Bibliográfica

Como Avaliar o Score?

- Para avaliar o score é necessário seguir um conjunto de passos;
- Primeiro é necessário calcular a função de perda do classificador;
 - SVM - (Multiclass Support Vector Machine);
 - Softmax - (Cross Entropy);

$$L = \frac{1}{n} \sum_{i=1}^n L_i + \sum_k w_k^2 \quad (3)$$

Backpropagation

- No final teremos uma equação e se temos uma equação conseguimos calcular o **gradiente**.

$$\nabla_w L = ??? \quad (4)$$

Backpropagation

- No final teremos uma equação e se temos uma equação conseguimos calcular o **gradiente**.

$$\nabla_w L = ??? \quad (4)$$

- Em outras palavras para calcular o backpropagation é necessário calcular vários gradientes de forma encadeada.

$$\nabla_w L = \frac{\partial L}{\partial w} \cdot \frac{\partial w}{\partial x_n} \quad (5)$$

Sumário

Introdução

MNIST and CIFAR10

Classificadores e Métricas

Otimização

Redes Neurais Artificiais

Resultados e Conclusão

Referência Bibliográfica

Redes Neurais Artificiais

- O que é uma rede neural?




Figure: Modelo de neurônio biológico [cs231n, 2018].

Redes Neurais Artificiais

- O que é uma rede neural?




Figure: Modelo de neurônio matemático [cs231n, 2018].

Redes Neurais Artificiais

- O que é uma rede neural?




Figure: Modelo de neurônio matemático [cs231n, 2018].

- **Um classificador Linear é Uma Rede Neural?**

Redes Neurais Artificiais

- O que é uma rede neural?




Figure: Modelo de neurônio matemático [cs231n, 2018].

- **Um classificador Linear é Uma Rede Neural?** R.: Na verdade é avaliador do conhecimento.

Sumário

Introdução

MNIST and CIFAR10

Classificadores e Métricas

Otimização

Redes Neurais Artificiais

Resultados e Conclusão

Referência Bibliográfica

Arquitetura: Camadas Totalmente Conectadas (fully connected)




Figure: [fully-connected, 2018]


What is Deep Learning?

- Qual a diferença entre uma *Rede Neural Simples* para uma *Rede Neural Profunda*?


What is Deep Learning?

- Qual a diferença entre uma *Rede Neural Simples* para uma *Rede Neural Profunda*?

Simple Neural Network



Deep Learning Neural Network



● Input Layer ● Hidden Layer ● Output Layer

Figure: Neural Network Sample and Deep [Deep, 2017].

K-Nearest Neighbor (MNIST)




Figure: Matriz de confusão do vizinho mais próximo - Neemias Bucéli

k-Nearest Neighbor (MNIST)




Figure: Matriz de confusão do vizinho mais próximo - Neemias Bucéli

Neural Network to Optimize Backpropagation (MNIST)

Para o treinamento da Rede foi utilizado, inicialmente, as seguintes características:

- **Época:** 10;
- **Quantidade de Neurônios:** 512;
- **Batch:** 128;
- **Arquitetura:** camadas totalmente conectadas;
- **Dropout:** 20%;
- **Função de ativação:** Rectifier;
- **Número de camadas:** 5.

Result of Neural Network Experiments – Backpropagation (MNIST)




Figure: Matriz de confusão do Backpropagation - Neemias Bucéli

Result of Neural Network Experiments – Backpropagation (MNIST)




Figure: Análise ROC do Backpropagation - Neemias Bucéli

Neural Network to Optimize Backpropagation (MNIST)

Tentativa de otimizar a Rede para ter um nível de acerto maior.

- **Época:** 50;
- **Quantidade de Neurônios:** 512;
- **Batch:** 128;
- **Arquitetura:** camadas totalmente conectadas;
- **Dropout:** 20%;
- **Função de ativação:** Rectifier;
- **Número de camadas:** 5.

Result of Neural Network Experiments – Backpropagation (MNIST)




Figure: Matriz de confusão do Backpropagation - Neemias Bucéli

Result of Neural Network Experiments – Backpropagation (MNIST)




Figure: Análise ROC do Backpropagation - Neemias Bucéli

Neural Network to Optimize RmsProp (MNIST)

Para o treinamento da Rede foi utilizando, inicialmente, as seguintes características:

- **Época:** 10;
- **Quantidade de Neurônios:** 512;
- **Batch:** 128;
- **Arquitetura:** camadas totalmente conectadas;
- **Dropout:** 20%;
- **Função de ativação:** Rectifier;
- **Número de camadas:** 5.

Result of Neural Network Experiments– RmsProp (MNIST)




Figure: Matriz de confusão do RmsProp - Neemias Bucéli

Result of Neural Network Experiments– RmsProp (MNIST)




Figure: Análise ROC do RmsProp - Neemias Bucéli

Neural Network to Optimize RmsProp (MNIST)

Para o treinamento da Rede foi utilizando, inicialmente, as seguintes características:

- **Época:** 20;
- **Quantidade de Neurônios:** 512;
- **Batch:** 128;
- **Arquitetura:** camadas totalmente conectadas;
- **Dropout:** 20%;
- **Função de ativação:** Rectifier;
- **Número de camadas:** 5.

Result of Neural Network Experiments– RmsProp (MNIST)




Figure: Matriz de confusão do RmsProp - Neemias Bucéli

Result of Neural Network Experiments– RmsProp (MNIST)




Figure: Análise ROC do RmsProp - Neemias Bucéli

K-Nearest Neighbor (CIFAR10)




Figure: Matriz de confusão do vizinho mais próximo - Neemias Bucéli

Neural Network to Optimize RmsProp (CIFAR10)

Para o treinamento da Rede foi utilizando, inicialmente, as seguintes características:

- **Época:** 200;
- **Quantidade de Neurônios:** 512;
- **Batch:** 128;
- **Arquitetura:** camadas totalmente conectadas;
- **Dropout:** 20%;
- **Função de ativação:** Rectifier;
- **Número de camadas:** 5.

Result of Neural Network Experiments– RmsProp (CIFAR10)




Figure: Matriz de confusão (fully connected) - Neemias Bucéli

Result of Neural Network Experiments– RmsProp (CIFAR10)




Figure: Análise ROC (fully connected) - Neemias Bucéli

E agora... O que FAZER???



Figure: Imagem capturada da internet. [HERA, 2015]

Convolution Neural Network – Entendendo um Pouco da História

- Em 1959: [Hubel, D. H. Wiesel, T. N. (1959)].
- O estudo focou no entendimento dos campos receptivos de neurônios no córtex de gatos.
- Vários neurônios aplicando convolução;
- Nós temos células simples: se existe bordas ou não.
- Células complexas e super complexas;

Convolution Neural Network – Entendendo um Pouco da História

- Em 1959: [Hubel, D. H. Wiesel, T. N. (1959)].
- O estudo focou no entendimento dos campos receptivos de neurônios no córtex de gatos.
- Vários neurônios aplicando convolução;
- Nós temos células simples: se existe bordas ou não.
- Células complexas e super complexas;

A publicação de Hubel et al., resultou no prêmio NOBEL em MEDICINA em 1960.

Convolution Neural Network




Figure: Imagem dos campos receptivos dos neurônios no cortex do gato.
[Hubel, D. H. Wiesel, T. N. (1959)]

Convolution Neural Network



Figure: Explicação do que é convolução. [Convolution, 2018]

Convolution Neural Network - CNN

- Uma CNN é uma sequência de camadas convolucionais seguidas por funções de ativação

$$CNN = w^T * x + b \quad (6)$$




Figure: 2D Convolution - Neemias

Convolution Neural Network (CIFAR10)

Para o treinamento da Rede foi utilizando, inicialmente, as seguintes características:

- **Época:** 200;
- **Quantidade de Neurônios:** 2112;
- **Batch:** 128;
- **Arquitetura:** Conv, MaxPooling, Flatten e Fully Connected;
- **Dropout:** 20%;
- **Função de ativação:** Rectifier;
- **Filtros para as Camadas de Convolução:** 576 (3x3);
- **Número de camadas:** 21.

Result of Convolution Neural Network Experiments – RMSprop (CIFAR10)




Figure: Matriz de confusão (Convolution) - Neemias Bucéli

Result of Neural Network Experiments– RMSprop (CIFAR10)




Figure: Análise ROC (Convolution) - Neemias Bucéli

Convolution Neural Network (CIFAR10)

Para o treinamento da Rede foi utilizando, inicialmente, as seguintes características:

- **Época:** 200;
- **Quantidade de Neurônios:** 2112;
- **Batch:** 128;
- **Arquitetura:** Conv, MaxPooling, Flatten e Fully Connected;
- **Dropout:** 20%;
- **Função de ativação:** Rectifier;
- **Filtros para as Camadas de Convolução:** 576 (3x3);
- **Número de camadas:** 21.

Result of Convolution Neural Network Experiments – Adam (CIFAR10)

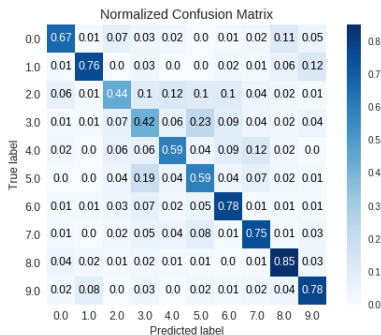


Figure: Matriz de confusão (Convolution) - Neemias Bucéli

Result of Neural Network Experiments– Adam (CIFAR10)




Figure: Análise ROC (Convolution) - Neemias Bucéli

RESUMINDO...

- Por isso é extremamente importante a fase dos testes *empíricos*, pois é através dele que podemos otimizar as nossas técnicas para alcançarmos um resultado **ótimo**.
- Em outras palavras, é através do caráter **artesanal** que otimizamos a técnica para o nosso problema.

RESUMINDO...

- Por isso é extremamente importante a fase dos testes *empíricos*, pois é através dele que podemos otimizar as nossas técnicas para alcançarmos um resultado **ótimo**.
- Em outras palavras, é através do caráter **artesanal** que otimizamos a técnica para o nosso problema.
- Por fim, alguma **dúvida** ou **pergunta** sobre a apresentação?

RESUMINDO...

- Por isso é extremamente importante a fase dos testes *empíricos*, pois é através dele que podemos otimizar as nossas técnicas para alcançarmos um resultado **ótimo**.
- Em outras palavras, é através do caráter **artesanal** que otimizamos a técnica para o nosso problema.
- Por fim, alguma **dúvida** ou **pergunta** sobre a apresentação?

FIM!!!

Sumário

Introdução

MNIST and CIFAR10

Classificadores e Métricas

Otimização

Redes Neurais Artificiais

Resultados e Conclusão

Referência Bibliográfica

Referência Bibliográfica



National Institute of Standards and Technology

NIST Available from World Wide Web: <https://www.nist.gov/>.



David Clifte da Silva Vieira e Renata Passos Machado

Abordagem a um classificador de dígitos manuscritos baseado em redes neurais.

VIICONNEPI - Congresso Norte Nordeste de Pesquisa e Inovação.



Patrick J. Grother, Visual Image Processing Group, Advanced Systems Division.

Handprinted Forms and Characters Database

NIST - National Institute of Standards and Technology.



MNIST data base.

Sample Images from MNIST test dataset.

MNIST Available from World Wide Web:

https://en.wikipedia.org/wiki/MNIST_database.

Referência Bibliográfica



cs231n Stanford University.

Neural Networks.

cs231n Available from World Wide Web:

<http://cs231n.github.io/neural-networks-1/>.



Deep Learning made easy with Deep Cogniton.

Flavio Vásquez.

Scientist Available from World Wide Web:

<https://becominghuman.ai/deep-learning-made-easy-with-deep-cognition-403fbe445351>.



Fully Connected.

Deep Learning.

Franck Available from World Wide Web:

<https://stats.stackexchange.com/questions/256342/how-many-learnable-parameters-does-a-fully-connected-layer-have-without-the-bias>.

Referência Bibliográfica



Vinod Nair and Geoffrey E. Hinton. 2010.

Rectified linear units improve restricted boltzmann machines.

In Proceedings of the 27th International Conference on International Conference on Machine Learning (ICML'10), Johannes Fürnkranz and Thorsten Joachims (Eds.). Omnipress, USA, 807-814.



The CIFAR-10 dataset (Mar 2013-Sep 2017) At Google in Mountain View, California.

Available from World Wide Web:

<https://www.cs.toronto.edu/~kriz/cifar.html>



Notice – HERA report R4-103 error alert

Available from World Wide Web:

<https://www.hera.org.nz/hera-report-r4103-error-alert/>

Referência Bibliográfica



Receptive Fields of Single Neurons in the Cat's Striate Cortex. *Journal of Physiology*, 148, 574–591.

Available from World Wide Web:

(<https://physoc.onlinelibrary.wiley.com/doi/abs/10.1113/jphysiol.1959.sp006308>)



Princípios de Processamento de Imagens: Uma introdução à Convolução.

Available from World Wide Web:

(<https://engenharia.elo7.com.br/convolucao/>)